

ČESKÉ VYSOKÉ UČENÍ TECHNICKÉ V PRAZE
FAKULTA STAVEBNÍ, OBOR GEODÉZIE A KARTOGRAFIE
KATEDRA GEOMATIKY

GOEINFORMATIKA

Vyhledávání objektů v mapách

Rok	Semestr	Skupina	Vypracovali	Datum
2025/2026	ZS	3	Vítěk Veselý František Gurecký	17. 11. 2025

1 Zadání

1.1 Část A

Implementujte algoritmus pro vyhledávání vzorů v Müllerově mapě Čech na základě obrazové korelace. Vyberte jeden z objektů typu obec s kostelem jako okno pro vyhledávání a na základě vhodné hodnoty korelace vyhledejte všechny pozice obcí s kostelem na mapovém listu. Výsledek odevzdejte jako pixelové souřadnice kostelů.

1.2 Část B

Implementujte algoritmus obrazové segmentace pomocí metody k-Means nad obrazem Topografické mapy ČSSR v měřítku 1 : 25 000. Výsledkem bude extrahovaná plocha lesů očištěná o vrstevnice a další překryvnou kresbu, naopak budou z lesů odečteny lesní průseky. Otvory v lesním prostoru větší než 50 pixelů zachovajte. Výsledek odevzdejte jako pole pixelových souřadnic.

2 Zpracování části A

2.1 Popis a rozbor problému

V této části byl implementován algoritmus pro vyhledávání obcí s kostelem v Müllerově mapě Čech. Detekce byla provedena pomocí obrazové korelace mezi vstupním mapovým listem a vzorem objektu.

Jelikož je Müllerova mapa historické kartografické dílo, má poněkud proměnlivou kresbu a různé lokální deformace. Z tohoto důvodu byla použita normalizovaná křížová korelace, která umožňuje robustnější vyhledávání vzoru i při přítomnosti šumu.

Cílem této části bylo nalézt všechny výskyty obcí s kostelem na daném mapovém listu a jejich souřadnice následně exportovat do textového formátu.

2.2 Popis použitých metod a algoritmů

2.2.1 Normalizovaná křížová korelace

Vyhledávání šablony bylo provedeno funkcí `normxcorr2`, která implementuje normalizovanou křížovou korelací. Ta je definována následujícím vztahem:

$$R(x, y) = \frac{\sum_{i,j} (d_1(c_1, r_1) - \bar{d}_1)(d_2(c_2, r_2) - \bar{d}_2)}{\sqrt{\sum_{i,j} (d_1(c_1, r_1) - \bar{d}_1)^2 \sum_{i,j} (d_2(c_2, r_2) - \bar{d}_2)^2}}, \quad (1)$$

kde d značí hodnotu pixelu na prvním, resp. druhém obrazu, \bar{d} je průměrná hodnota pixelu ve vyhledávacím okně c , r značí sloupec a řádek pixelu na obrazu a i, j jsou indexy polohy vyhledávacího okna.

Korelační koeficient r se pohybuje v intervalu $[-1, 1]$, přičemž vysoké kladné hodnoty indikují dobrou shodu.

Vzorec je uveden v poskytnuté prezentaci (CAJTHAML, Jiří a JANATA, Tomáš. Detekce vzorů v obrazech, segmentace obrazu, strojové učení. Online. In: . S. 24. Dostupné z: https://maps.fsv.cvut.cz/~cajthaml/ygei/YGEI_Obráz.pdf. [cit. 2025-11-17].), podobná implementace je uvedena v dokumentaci MATLABu.

2.2.2 Průměrování více vzorů

Vzhledem k variabilitě kresby objektů bylo vybráno pět výřezů obsahující hledaný prvek. Každý výřez byl reprezentován jako obraz T_k a následně byl vytvořen průměrný vzor:

$$T_{\text{avg}} = \frac{1}{n} \sum_{k=1}^n T_k. \quad (2)$$

Takto vytvořený průměrný vzor snižuje vliv šumu a lokálních odchylek kresby.

Následně byla lokální maxima filtrována prahováním korelace s využitím hodnoty 0.60.

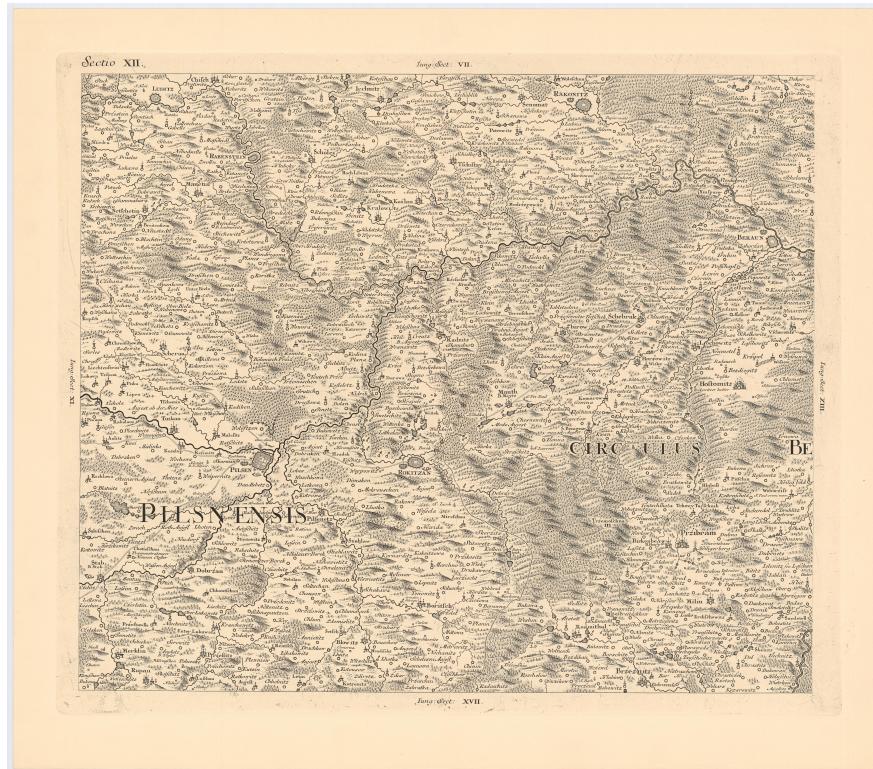
2.2.3 Detekce lokálních maxim

Aby bylo zajištěno, že pro jedno místo nebude vráceno více detekcí, byla provedena extrakce lokálních maxim z korelační mapy. Lokální maxima byla určena výrazem:

$$L(x, y) = \begin{cases} 1, & \text{pokud } R(x, y) \text{ je lokálním maximem,} \\ 0, & \text{jinak.} \end{cases}$$

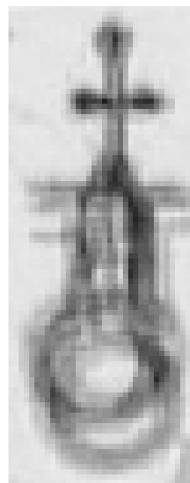
Tato detekce byla realizována funkcí `imregionalmax`.

2.3 Vstupní data



Obrázek 1: Zadaný výřez Müllerovy mapy Čech

Ručním výběrem bylo určeno několik souřadnic obsahujících objekt typu „obec s kostelem“. Z těchto souřadnic byly oříznuty výřezy o velikosti 35×92 px, které sloužily jako vstupní vzory pro vytvoření průměrného vzoru.



Obrázek 2: Průměrný vzor použitý pro korelací

2.4 Výstupní data

2.4.1 Souřadnice nalezených objektů

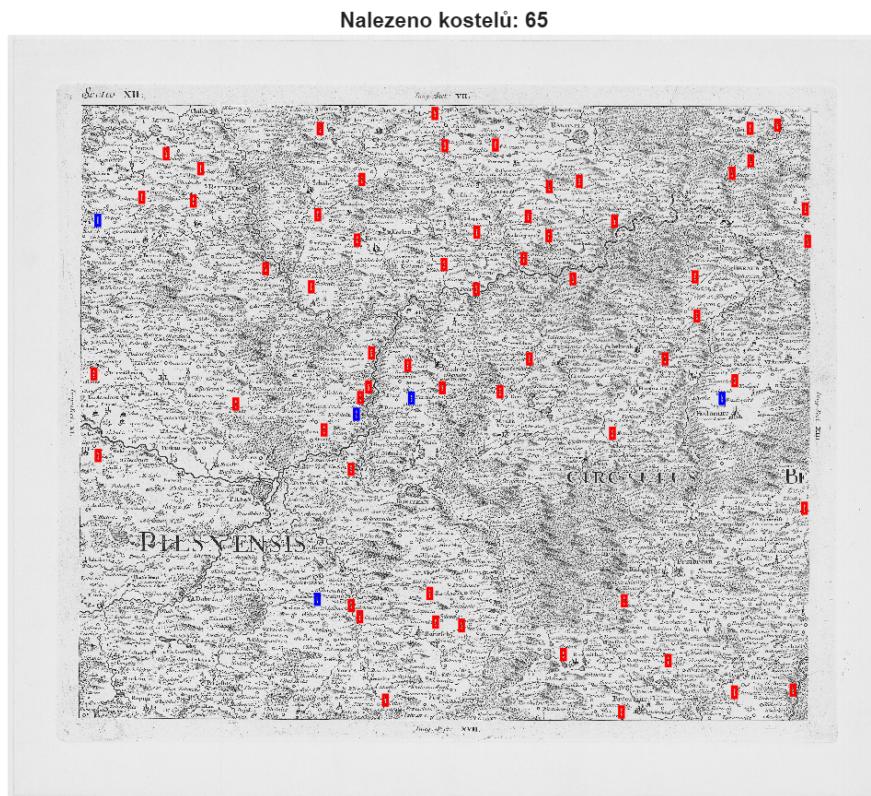
Výsledkem detekce je množina dvojic pixelových souřadnic:

$$(x_1, y_1), \dots, (x_N, y_N),$$

kde každý pár udává pozici levého horního rohu nalezeného výskytu prvku o stejné velikosti jako vzor. Výsledky byly exportovány ve formátu CSV pomocí funkce `writematrix`.

2.4.2 Grafická vizualizace

Pro účely validace byla vytvořena vizualizace detekovaných prvků. Nalezené kostely byly označeny červenými rámečky, zatímco pozice původních ručně vybraných vzorů byly zvýrazněny modrou barvou. Tím bylo umožněno vizuální ověření funkčnosti algoritmu.



Obrázek 3

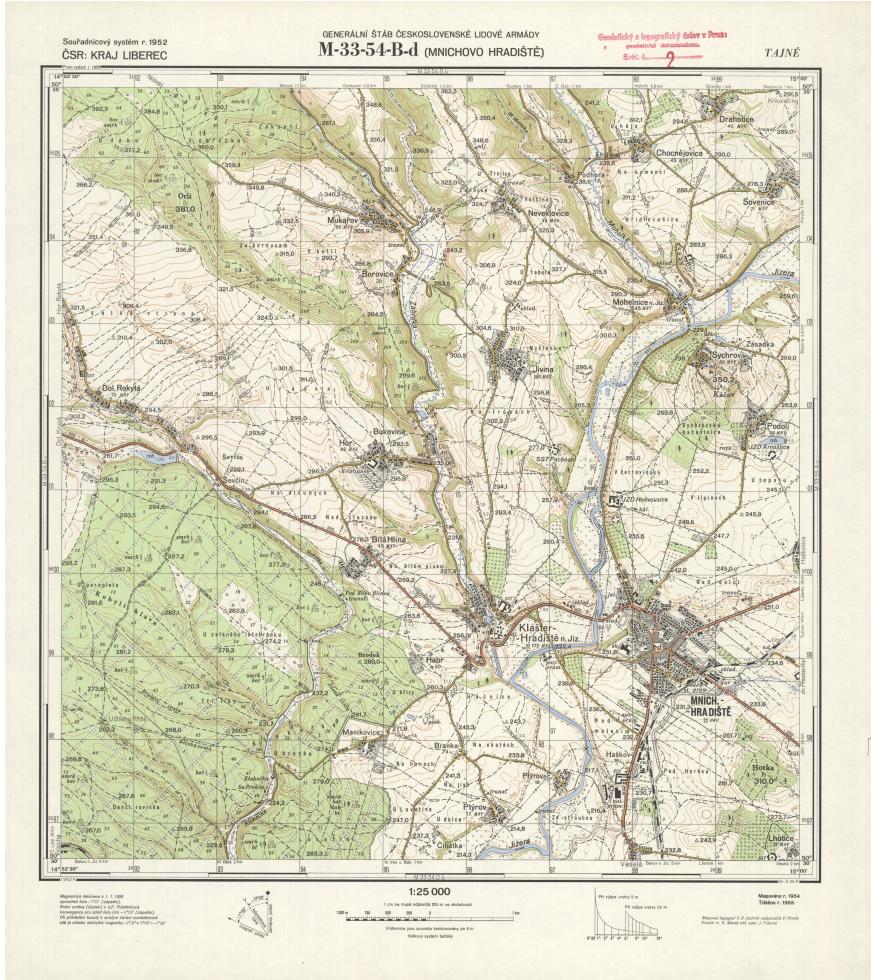
2.5 Závěr a možné problémy

Použitý postup umožnil spolehlivou detekci kostelů v Müllerově mapě pomocí normalizované korelace. Přesto zůstává několik omezení, která nebyla v rámci implementace řešena:

- citlivost na rotaci objektu – šablona se shoduje pouze při shodné orientaci,
- citlivost na změnu měřítka – korelace předpokládá shodnou velikost vzoru,
- vyšší výpočetní náročnost u velkých obrazů,
- nutnost ručního výběru počátečních vzorů.

Prahová hodnota korelace 0.60 se ukázala pro zadaný výřez jako optimální, při jejím zvýšení již dochází k chybné detekci dalších obcí, hlavně těch, jejichž mapové značky obsahují věže. Naopak při snížení nejsou detekovány ty obce s kostelem, u kterých zasahuje do hledaného okna například trocha textu. Stejně jako prahová hodnota se hlavně z důvodu výskytu textu ukázala jako nejvhodnější velikost vzoru 35×92 px.

3 Zpracování části B



Obrázek 4: Zadaný sken TM25

3.1 Postup práce

Cílem této části bylo vytvořit binární masku lesních ploch z dostupné topografické mapy ČSSR pomocí neřízené klasifikace K-means. Metoda umožňuje automaticky rozdělit pixely obrazu do několika skupin na základě jejich spektrálních vlastností, aniž by bylo nutné dopředu zadávat trénovací data. Po klasifikaci byly identifikovány ty pixely, které svými spektrálními hodnotami odpovídaly vegetaci, a z nich byla vytvořena výsledná binární maska.

3.2 Teoretické základy metody K-means

Metoda K-means je jednou z nejpoužívanějších technik neřízené klasifikace, která rozděluje množinu dat do předem zvoleného počtu K clusterů. Každý pixel je přiřazen k tomu clusteru, jehož centroid má nejbližší spektrální hodnotu. Vzdálenost mezi pixelem a centroidem je stanovena pomocí Eukleidovské vzdálenosti v RGB prostoru:

$$d(x_i, c_j) = \sqrt{(R_i - R_j)^2 + (G_i - G_j)^2 + (B_i - B_j)^2}. \quad (3)$$

Po přiřazení všech pixelů se centroidy aktualizují jako průměr všech pixelů náležících příslušnému clusteru:

$$c_j = \frac{1}{n_j} \sum_{i=1}^{n_j} x_i, \quad (4)$$

kde n_j představuje počet pixelů přiřazených ke clusteru j . Cílem algoritmu je minimalizovat sumu čtvercových vzdáleností mezi pixely a jejich centroidy, která je dána vztahem:

$$J = \sum_{j=1}^K \sum_{x_i \in C_j} \|x_i - c_j\|^2. \quad (5)$$

Tato minimalizace probíhá iterativně, dokud změny centroidů nejsou zanedbatelné nebo dokud není dosaženo maximálního počtu iterací.

3.3 Postup zpracování obrazu

Nejprve byl načten vstupní RGB ortofotografický snímek a jeho hodnoty byly v případě potřeby normalizovány do rozsahu $\langle 0, 1 \rangle$. Snímek byl následně převeden do vektorové formy, kde každý pixel je reprezentován trojicí hodnot odpovídajících kanálům R, G a B. Na takto připravená data byla aplikována metoda K-means se dvěma clustery, které reprezentovaly třídy „les“ a „neles“. Inicializace centroidů byla provedena pomocí metody k-means++, což zajistuje stabilnější výběr počátečních hodnot.

Samotná klasifikace probíhala iterativně. V každém kroku byly pixely přiřazeny k nejbližšímu centroidu vypočtenému podle jejich spektrální vzdálenosti. Následně byly centroidy aktualizovány jako průměrné hodnoty všech pixelů příslušejících ke stejnemu clusteru. Tento postup se opakoval až do dosažení stabilizace clusterů.

3.3.1 Tvorba binární masky lesa

Po dokončení klasifikace vznikl rastrový obraz obsahující dvě třídy, z nichž jedna odpovídala lesním plochám. Cluster reprezentující vegetaci byl vybrán na základě vizuální kontroly a jeho spektrálních charakteristik, které zahrnovaly nižší jas a typickou barevnou homogenitu lesních oblastí. Z vybraného clusteru byla vytvořena binární maska podle následující definice:

$$\text{Maska}(x) = \begin{cases} 1, & \text{pokud pixel patří do clusteru lesa,} \\ 0, & \text{jinak.} \end{cases} \quad (6)$$

Takto vytvořená maska jednoznačně odděluje lesní plochy od ostatního povrchu.

3.3.2 Postprocessing

Aby byla výsledná maska co nejpřesnější, byl proveden i následný postprocessing. Maska byla vyhlazena pomocí morfologických operací, zejména otevření a uzavření, které umožnily odstranit malé izolované pixely a vyplnit menší mezery v lesních celcích. Dále byly odstraněny velmi malé objekty, které neodpovídaly skutečným lesním plochám a vznikly pouze jako artefakty klasifikace. Výsledkem je kompaktnější a lépe interpretovatelná maska.

3.4 Interpretace výsledků

Výsledná binární maska odlišuje lesní oblasti od ostatních typů povrchu. Metoda K-means se ukázala jako vhodná pro rozpoznání rozsáhlých a kompaktních lesních celků díky tomu, že les obvykle tvoří spektrálně homogenní skupinu. Méně spolehlivé výsledky mohou vznikat v oblastech se stínem nebo tam, kde mají některé objekty podobné spektrální vlastnosti jako les. Přesto metoda umožňuje rychlou a efektivní segmentaci lesních ploch bez nutnosti použití trénovacích dat.



Obrázek 5

3.5 Výhody, nevýhody a možnosti rozšíření

Výhodou metody K-means je její jednoduchost, rychlosť výpočtu a nezávislost na trénovacích dotech. Je však třeba zmínit i nevýhody, mezi které patří nutnost volby vhodného počtu clusterů a citlivost na různorodé světelné podmínky ve scéně. Algoritmus navíc nebene v úvahu prostorové uspořádání pixelů, což může vést k menšímu šumu na hranách objektů. V budoucnu by bylo možné metodu rozšířit například o použití vyšší hodnoty K s následnou agregací tříd, integraci vegetačních indexů, případně využití pokročilejších řízených klasifikačních algoritmů, jako je metodika Random Forest nebo SVM.

3.6 Závěr

V této části byla úspěšně vytvořena binární maska lesních ploch na základě neřízené klasifikace K-means. Postup umožnil efektivní rozdelení obrazu do dvou tříd, přičemž jedna z nich reprezentovala vegetaci, a mohla tak být extrahována jako samostatná maska. Výsledná maska poskytla přehledné a konzistentní vymezení lesních celků, zejména díky následným morfologickým úpravám, které napomohly odstranění šumu, malých izolovaných oblastí jako a kresby v mapě, která lesní plochu kryla.

4 Přílohy

Veškeré přílohy jsou dostupné v GitHub repozitáři dostupného na odkaze:

https://github.com/gureckyfrantisek/155YGEI_2025/tree/main/Uloha2.

Úloha 2 je ve své složce, jsou zde také výstupní soubory, výpočetní skripty.

5 Závěr k úloze

V části A se podařilo splnit celou úlohu i s bonusovými podúlohami, výsledky vypadají obstojně, podrobněji jsou popsány v 2.5.

V části B se podařilo dobré splnit pouze základní segmentaci metodou k-means, pro Gaborův ani STD filtr se nám nepodařilo získat dobré výsledky, možné implementace jsou však v repozitáři také. Závěr k této části je rovněž podrobněji rozepsán v 3.6.

Celkově se podařilo splnit celou část A a alespoň povinnou část B této úlohy.

V Praze dne 17. 11. 2025

**Vítěk Veselý
František Gurecký**